

SK네트웍스 Family AI 캠프 29회차

LLM(초거대언어모델) 프로젝트 평가

□ 개요

- 프로젝트 명 : LLM을 연동한 내외부 문서 기반 질의응답 시스템
- 평가 산출물 : 수집된 데이터 및 데이터 전처리 문서, 시스템 아키텍처, 개발된 소프트웨어: RAG 기반 LLM과 벡터 데이터베이스 연동 구현 코드, 테스트 계획 및 결과 보고서
- 깃허브 주소 : <https://github.com/SKNETWORKS-FAMILY-AICAMP>
- 평가 일시 :
- 평가 대상 :
- 평가 강사 :

□ 평가 기준

산출물	평가 요소	배점	점수
수집된 데이터 및 데이터 전처리 문서	데이터 수집 및 구축의 적절성 • 커리큘럼 내 NLP 어플리케이션 목적에 맞는 데이터셋(코퍼스) 선정이 타당한가? • 데이터의 편향성, 중복성, 결측치 처리가 올바르게 수행되었는가? 텍스트 전처리 및 형태소 분석 기술 적용도 • 정규표현식 및 KoNLPy를 활용하여 한국어 특성에 맞는 형태소 분석 및 불용어(Stopwords) 처리가 정밀하게 이루어졌는가? • 희소 표현(BoW, TF-IDF) 및 밀집 임베딩(Word2Vec, FastText)을 위한 텍스트 정규화가 수행되었는가? RAG/Graph 최적화 청킹(Chunking) 전략 • Vector DB 및 Graph DB 입력을 위해 문맥을 보존하는 적절한 청킹 전략(Fixed-size, Recursive, Semantic Chunking 등)을 설계하고 문서화했는가? 문서화의 완성도 • 데이터 스키마, 전처리 파이프라인 흐름, 데이터의 수량이 명확히 정의되고 기록되었는가?	20	

시스템 아키텍처	아키텍처 설계의 타당성 및 확장성 - LLM, Vector DB(Chroma 등), Graph DB(Neo4j 등)의 컴포넌트 구성이 Hybrid RAG 목적에 맞게 효율적으로 설계되었는가? - LangGraph 기반의 Multi-Agent 로직(Sequential, Router, Supervisor 등)의 데이터 흐름과 제어 흐름이 명확히 시각화되었는가? MCP(Model Context Protocol) 및 외부 연동 설계 - 외부 서비스 및 API 연동을 위한 MCP Server의 구조와 라우팅 설계가 보안 및 성능 관점에서 타당한가? 컴포넌트 간 인터페이스 및 데이터 흐름 정의 - 프롬프트 엔지니어링 계층, 파싱/라우팅 계층, 메모리 컴포넌트 간의 I/O 데이터 포맷이 명확하게 정의되었는가?	20	
개발된 소프트웨어: RAG 기반 LLM과 벡터 데이터베이스 연동 구현 코드	Hybrid RAG 및 DB 연동의 완성도 - Vector DB와 Graph DB에서 정보를 효과적으로 Retrieval(검색)하고 이를 프롬프트에 결합하는 Hybrid RAG 파이프라인이 정상 작동하는가? - Top P, Temperature 등 LLM 파라미터를 Use Case(질의응답, 요약 등)에 맞게 동적으로 제어하는가? Multi-Agent 및 ReAct 워크플로우 구현 - 에이전트가 사용자의 의도를 파악하여 도구(Tool)를 선택하고, ReAct(Reason + Act) 루프를 통해 올바른 결론을 도출하는가? - LangGraph 내 Router 및 Supervisor 로직이 엔드포인트 간의 무한 루프 없이 안정적으로 구동되는가? sLLM 파인튜닝 및 최적화 코드 역량 - LoRA/QLoRA 기법을 활용한 PEFT 파인튜닝 코드가 메모리 효율성(Gradient Clipping 등)을 고려하여 올바르게 작성되었는가? 코드 품질 및 예외 처리 (Code Quality) - API 호출 실패, DB Connection 오류, LLM의 잘못된 출력 형식(Parsing Error)에 대한 예외 처리(Error Handling)가 철저한가? - 모듈화가 잘 되어 있으며, Clean Code 원칙을 준수했는가?	40	
테스트 계획 및 결과 보고서	검증 시나리오 및 테스트 계획의 구체성	20	

	- RAG 시스템의 성능을 평가하기 위한 테스트 데이터셋(Ground Truth)과 시나리오가 객체적으로 수립되었는가? 자연어 및 생성 모델 전문 평가 지표 활용도 - 번역, 요약, 문장 생성 결과에 대해 BLEU, ROUGE 지표를 올바르게 산출했는가? - 파인튜닝된 sLLM의 성능 측정을 위해 LM-Eval(lm-evaluation-harness) 모듈을 활용한 벤치마크 테스트를 수행했는가? RAG 및 LLM 전용 평가(LLM-as-a-Judge) 적용 - GPT 등을 활용하여 RAG의 핵심 요소인 Context Relevance(맥락 관련성), Groundedness(실제성/환각 여부), Answer Relevance(답변 관련성)를 평가했는가? 멀티모달 결과 검증 (선택적 포함) - 커리큘럼 후반부의 Image Captioning 이나 Stable Diffusion 결과물에 대한 정성적/정량적 평가가 포함되었는가? 피드백 및 개선안 도출 - 테스트 결과 발생한 한계점(환각 현상, 레이턴시 지연, 에이전트 라우팅 실패 등)을 분석하고, 이를 해결하기 위한 향후 프롬프트 수정 및 추가 파인튜닝 방향성을 논리적으로 제시했는가?		
		100	

□ 평가 의견

-